

PROJETO PRÁTICO – CHECK POINT 2
APRENDIZADO PROFUNDO CONVOLUCIONAL COM REDES NEURAIS CONVOLUCIONAIS

Classificação binária: preparação de dados, experimentação de arquiteturas e seleção do modelo

Integrantes (nome completo e RM):	Turma:
Data de entrega:	Valor: 10 pontos

1. CONTEXTO DO PROJETO

Neste projeto, os alunos deverão aplicar o fluxo completo de um problema supervisionado de classificação binária. A proposta é partir de uma base de dados real, compreender e preparar os dados, construir diferentes redes neurais multicamadas (MLP), comparar sistematicamente suas arquiteturas e justificar qual configuração é mais adequada para o problema escolhido.

A análise deve privilegiar o método experimental: a comparação entre modelos só será válida se os conjuntos de dados e as demais condições de treinamento forem controlados. O objetivo não é apenas obter uma boa métrica, mas demonstrar compreensão sobre como a arquitetura da MLP afeta o aprendizado e a capacidade de generalização.

2. OBJETIVO GERAL

Desenvolver, avaliar e comparar diferentes arquiteturas de MLP para um problema real de classificação binária, identificando a configuração que apresenta o melhor equilíbrio entre desempenho, estabilidade e capacidade de generalização.

3. ESCOLHA DA BASE DE DADOS

A base selecionada deverá atender aos seguintes requisitos:

- representar um problema de classificação binária, com apenas duas classes no target;
- ser uma base tabular, com atributos numéricos, categóricos ou ambos;
- possuir quantidade de amostras suficiente para separar dados de treino, validação e teste;
- ter origem identificável e permitir a descrição clara do problema, das features e do target;
- ser diferente da base UCI Bank Marketing utilizada nas aulas;
- não exigir arquiteturas específicas para imagens, texto bruto, áudio ou outros dados não tabulares.

No relatório, devem constar a fonte da base, uma breve descrição do problema e a definição explícita da classe positiva e da classe negativa.

4. ETAPAS OBRIGATÓRIAS

4.1 Entendimento e exploração dos dados

- Identificar o número de amostras e de features.
- Separar claramente quais variáveis são numéricas, categóricas e qual é o target.
- Verificar dados ausentes, valores codificados como ausência, categorias desconhecidas e duplicatas.
- Analisar a distribuição das classes e informar se existe desbalanceamento.
- Calcular estatísticas descritivas adequadas às variáveis numéricas e realizar explorações que ajudem a compreender o problema.
- Investigar possíveis variáveis que possam causar data leakage e justificar qualquer remoção.

4.2 Tratamento e preparação da base

- Tratar valores ausentes ou inconsistentes, justificando as decisões adotadas.
- Tratar duplicatas quando necessário, considerando o significado dos registros.
- Transformar variáveis categóricas em representação numérica apropriada.
- Padronizar ou normalizar variáveis numéricas quando necessário para o treinamento da rede neural.
- Garantir que qualquer transformação aprendida a partir dos dados seja ajustada somente no conjunto de treino e depois aplicada à validação e ao teste.
- Documentar todas as etapas de pré-processamento para permitir a reprodução do experimento.

4.3 Divisão dos dados

A divisão deverá ser realizada antes de aprender transformações de pré-processamento. Utilize como referência:

Conjunto	Proporção sugerida	Finalidade
Treino	70%	Ajustar os parâmetros da MLP.
Validação	15%	Comparar arquiteturas e apoiar decisões de modelagem.
Teste	15%	Realizar a avaliação final do modelo escolhido.

A divisão deve ser estratificada para preservar, tanto quanto possível, a proporção das duas classes em treino, validação e teste.

O conjunto de teste não deve ser usado para escolher arquitetura, número de neurônios, função de ativação ou qualquer outra decisão de modelagem.

4.4 Construção das MLPs

Treine diferentes MLPs mantendo a camada de saída adequada à classificação binária. A saída deverá produzir uma probabilidade para a classe positiva, com função de ativação sigmoid e função de perda apropriada à classificação binária.

Cada experimento deve registrar, no mínimo:

- quantidade de camadas intermediárias;
- quantidade de neurônios em cada camada intermediária;
- função de ativação das camadas intermediárias;
- função de ativação da camada de saída;
- função de perda;
- taxa de aprendizado;
- número de épocas;
- tamanho do batch, quando aplicável;
- demais parâmetros de treinamento usados no framework escolhido.

5. PLANO MÍNIMO DE EXPERIMENTAÇÃO

O trabalho deve comparar no mínimo 7 arquiteturas distintas. A comparação deve ser organizada de forma que seja possível observar separadamente o efeito da largura da rede, da profundidade e da função de ativação. O quadro abaixo apresenta um plano mínimo recomendado.

Experimento	Objetivo da comparação	Camadas intermediárias	Ativação
E1	Referência	1 camada com 16 neurônios	ReLU
E2	Efeito da largura	1 camada com 32 neurônios	ReLU
E3	Efeito da largura	1 camada com 64 neurônios	ReLU
E4	Efeito da profundidade	2 camadas: 32 e 16	ReLU
E5	Efeito da profundidade	3 camadas: 64, 32 e 16	ReLU
E6	Efeito da ativação	mesma arquitetura de E2	tanh
E7	Efeito da ativação	mesma arquitetura de E2	sigmoid

Os alunos podem acrescentar outras arquiteturas e ajustar as configurações do quadro, desde que mantenham pelo menos 7 experimentos e preservem comparações controladas. Ao comparar uma característica, mantenha as demais condições de treinamento constantes sempre que possível.

6. TREINAMENTO E REGISTRO DOS RESULTADOS

- Utilizar exatamente os mesmos conjuntos de treino e validação em todas as arquiteturas.
- Manter uma semente aleatória fixa quando o framework permitir, facilitando a reprodução dos resultados.
- Registrar o desempenho de treino e validação de cada arquitetura.
- Observar sinais de underfitting ou overfitting a partir do comportamento do modelo em treino e validação.
- Não alterar o conjunto de teste após o início dos experimentos.
- Guardar os resultados de todos os experimentos, inclusive modelos que apresentarem desempenho inferior.

7. AVALIAÇÃO DOS MODELOS

Cada arquitetura deve ser avaliada no conjunto de validação utilizando, no mínimo:

- loss de validação;
- acurácia;
- precisão;
- recall;
- F1-score;
- matriz de confusão.

A escolha da melhor arquitetura não poderá ser baseada apenas na acurácia. Os alunos deverão considerar a distribuição das classes e discutir quais erros são mais relevantes no contexto do problema escolhido. Quando houver desbalanceamento, a análise deve dar atenção especial às métricas da classe positiva.

8. SELEÇÃO DA ARQUITETURA MAIS ADEQUADA

A arquitetura final deverá ser escolhida exclusivamente a partir do desempenho no conjunto de validação e da análise crítica dos resultados. A justificativa deve discutir, pelo menos, os seguintes aspectos:

- desempenho nas métricas de validação;
- diferença entre desempenho de treino e validação;
- efeito observado ao aumentar ou reduzir a quantidade de neurônios;
- efeito observado ao aumentar o número de camadas intermediárias;
- efeito das diferentes funções de ativação;
- complexidade da arquitetura em relação ao ganho obtido;
- tipo de erro mais importante para o problema estudado.

Somente após a escolha da arquitetura deverá ser realizada a avaliação final no conjunto de teste. O resultado de teste deve ser apresentado como estimativa final do desempenho do modelo em dados não utilizados nas decisões de modelagem.

9. TABELA OBRIGATÓRIA DE COMPARAÇÃO

O relatório deve apresentar uma tabela consolidada com todos os experimentos. Utilize, no mínimo, as colunas abaixo:

ID	Camadas	Ativação	Loss val.	Acurácia	Precisão	Recall	F1
E1							
E2							
E3							

A tabela final deverá conter todos os experimentos realizados, não apenas a arquitetura escolhida.

10. QUESTÕES QUE DEVEM SER RESPONDIDAS NO RELATÓRIO

1. Qual é o problema de classificação binária escolhido e qual é a classe positiva?
2. Quais problemas de qualidade foram encontrados na base e como foram tratados?
3. Existe desbalanceamento entre as classes? Qual o impacto disso sobre a interpretação das métricas?
4. Quais transformações foram aplicadas às variáveis numéricas e categóricas? Em qual conjunto essas transformações foram ajustadas?
5. Como a quantidade de neurônios afetou o desempenho da MLP?
6. Como o aumento do número de camadas intermediárias afetou o desempenho?
7. Qual foi o efeito das funções de ativação testadas?

8. Houve indícios de underfitting ou overfitting em alguma arquitetura? Explique.
9. Qual arquitetura foi selecionada e por quê?
10. Como a arquitetura escolhida se comportou no conjunto de teste? O resultado foi consistente com a validação?

11. ORGANIZAÇÃO DOS GRUPOS E SUBMISSÃO

- O trabalho poderá ser realizado individualmente ou em grupos de até 3 integrantes.
- A identificação de todos os integrantes deverá constar obrigatoriamente no relatório e no notebook, incluindo nome completo e RM/identificação acadêmica.
- No notebook, a identificação do grupo deverá aparecer logo no início, preferencialmente na primeira célula Markdown.
- No relatório, a identificação completa de todos os integrantes deverá aparecer na primeira página, juntamente com a turma.
- Apenas um integrante do grupo deverá realizar a submissão no Microsoft Teams. Não é necessário que os demais integrantes façam submissões duplicadas.

12. ENTREGÁVEIS

Devem ser submetidos no Microsoft Teams somente os dois entregáveis abaixo:

- Notebook Jupyter/Google Colab (.ipynb) executável do início ao fim, contendo carregamento da base, EDA, tratamento, pré-processamento, treinamento, avaliação e comparação das diferentes arquiteturas de MLP.
- Relatório técnico contendo todas as seções obrigatórias descritas na Seção 13.

O notebook e o relatório devem apresentar resultados compatíveis entre si. A fonte original da base de dados deve ser informada nos dois arquivos, e o notebook deve conter as instruções necessárias para obtenção ou carregamento dos dados.

13. ESTRUTURA OBRIGATÓRIA DO RELATÓRIO

O relatório deverá conter, na ordem abaixo, todas as seções indicadas:

13.1 Identificação - título do projeto, turma, nome completo e RM/identificação acadêmica de todos os integrantes do grupo.

13.2 Introdução e definição do problema - contextualização do problema de classificação binária, objetivo da análise e definição das classes positiva e negativa.

13.3 Descrição da base de dados - nome e fonte da base, quantidade de amostras e features, descrição do target e identificação das variáveis numéricas e categóricas.

13.4 Análise exploratória dos dados (EDA) - análise de tipos de dados, estatísticas descritivas, dados ausentes, valores desconhecidos, duplicatas, distribuição das classes, desbalanceamento e possíveis indícios de data leakage.

13.5 Tratamento e preparação dos dados - descrição e justificativa das etapas de limpeza, tratamento de ausentes e duplicatas, codificação das variáveis categóricas, padronização ou normalização e demais transformações aplicadas.

13.6 Metodologia experimental - estratégia de divisão em treino, validação e teste; uso de estratificação; cuidados para evitar leakage; semente aleatória; função de perda; otimizador; taxa de aprendizado; número de épocas; batch size e demais parâmetros de treinamento.

13.7 Arquiteturas de MLP avaliadas - apresentação das arquiteturas testadas, incluindo número de camadas intermediárias, quantidade de neurônios por camada e funções de ativação. Devem ser apresentados no mínimo 7 experimentos distintos.

13.8 Resultados - apresentação organizada dos resultados de treino e validação, incluindo a tabela comparativa obrigatória, métricas solicitadas, matriz de confusão e demais gráficos ou informações relevantes para interpretar o treinamento.

13.9 Análise comparativa e seleção da arquitetura - comparação crítica entre os experimentos, discussão dos efeitos da largura, profundidade e funções de ativação, identificação de possíveis sinais de underfitting ou overfitting e justificativa da arquitetura escolhida.

13.10 Avaliação final no conjunto de teste - avaliação da arquitetura selecionada exclusivamente após a etapa de escolha com a validação, apresentando as métricas finais e discutindo a consistência entre validação e teste.

13.11 Conclusão - síntese dos principais resultados, resposta ao objetivo proposto, limitações do experimento e principais aprendizados obtidos.

13.12 Referências - fonte da base de dados e demais materiais, artigos, documentação ou referências utilizadas no desenvolvimento do projeto.

14. CRITÉRIOS DE AVALIAÇÃO

Critério	O que será observado	Pontos
Definição do problema e entendimento da base	Problema, target, classes, features e fonte dos dados.	10
EDA e tratamento dos dados	Exploração, ausentes/duplicatas, distribuição das classes e leakage.	20
Pré-processamento e divisão	Transformações, split estratificado e prevenção de vazamento de dados.	15
Experimentação com MLP	Variação controlada de profundidade, neurônios e ativações.	25
Avaliação e seleção do modelo	Métricas, comparação e justificativa da arquitetura escolhida.	20
Reprodutibilidade e apresentação	Código executável, organização e clareza dos resultados.	10

15. REGRAS IMPORTANTES

- Trabalhos em grupo podem ter no máximo 3 integrantes.
- A ausência da identificação completa de qualquer integrante no relatório ou no notebook poderá impedir a correta atribuição da entrega ao grupo.
- Somente uma pessoa do grupo deverá depositar o notebook e o relatório no Microsoft Teams.
 - Não será considerado suficiente treinar apenas uma única MLP.
 - Não é permitido selecionar a arquitetura final utilizando o conjunto de teste.
 - A comparação deve apresentar todos os modelos testados e não somente o melhor resultado.
 - Toda decisão de limpeza, exclusão de variável ou transformação deve ser justificada.
 - O resultado deve ser interpretado no contexto do problema; uma métrica isolada não substitui a análise crítica.
 - A reprodução do notebook deve gerar os resultados apresentados no relatório, respeitadas pequenas variações numéricas inerentes ao treinamento.

16. RESULTADO ESPERADO

Ao final do projeto, o aluno deverá ser capaz de demonstrar um fluxo completo de modelagem com MLP: compreender o problema, preparar corretamente os dados, construir e treinar redes com diferentes configurações, avaliar os resultados de forma adequada e defender tecnicamente a escolha da arquitetura mais apropriada para o problema de classificação binária estudado.